Формула размера выборки для бинарной метрики

Идея расчёта состоит в том, чтобы расположить распределения под H_0 и H_1 достаточно далеко друг от друга.

Пусть истинный эффект равен

$$\Delta = p_2 - p_1.$$

Критическая граница со стороны H_0 находится на расстоянии

$$z_\alpha SE$$

от центра распределения H_0, а для обеспечения мощности $1-\beta$ центр распределения H_1 должен находиться ещё на расстоянии

$$z_\beta SE$$

от этой границы.

В классической формуле предполагается, что стандартная ошибка под H_0 и H_1 одинакова. Поэтому:

$$\Delta = z_\alpha SE + z_\beta SE.$$

Или:

$$\Delta = (z_\alpha + z_\beta)SE.$$

Именно отсюда возникает классическая структура:

$$n = \frac{2Var_{\text{hist}}(z_\alpha + z_\beta)^2}{\Delta^2}.$$

Для бинарной метрики это предположение можно ослабить, поскольку дисперсия зависит от самой вероятности:

$$Var(X) = p(1-p).$$

Поэтому стандартная ошибка под H_0 и стандартная ошибка под H_1 в общем случае различаются:

$$SE_0 \neq SE_1.$$

Тогда вместо

$$\Delta = z_\alpha SE + z_\beta SE$$

получаем:

$$\boxed{\Delta = z_\alpha SE_0 + z_\beta SE_1}$$

Под H_0:

$$Control = p_1, \qquad Test = p_1.$$

Поэтому:

$$SE_0 = \sqrt{\frac{p_1(1-p_1) + p_1(1-p_1)}{n}} = \frac{\sqrt{2p_1(1-p_1)}}{\sqrt{n}}.$$

Под H_1:

$$Control = p_1, \qquad Test = p_2.$$

Поэтому:

$$SE_1 = \sqrt{\frac{p_1(1-p_1) + p_2(1-p_2)}{n}} = \frac{\sqrt{p_1(1-p_1) + p_2(1-p_2)}}{\sqrt{n}}.$$

Подставляем SE_0 и SE_1:

$$\Delta = z_\alpha \frac{\sqrt{2p_1(1-p_1)}}{\sqrt{n}} + z_\beta \frac{\sqrt{p_1(1-p_1) + p_2(1-p_2)}}{\sqrt{n}}.$$

Умножаем на $\sqrt{n}$:

$$\Delta\sqrt{n} = z_\alpha \sqrt{2p_1(1-p_1)} + z_\beta \sqrt{p_1(1-p_1) + p_2(1-p_2)}.$$

Отсюда:

$$\boxed{n = \frac{\left[z_\alpha \sqrt{2p_1(1-p_1)} + z_\beta \sqrt{p_1(1-p_1) + p_2(1-p_2)}\right]^2}{(p_2 - p_1)^2}}$$

где для two-sided теста

$$z_\alpha = z_{1-\alpha/2},$$

для one-sided теста

$$z_\alpha = z_{1-\alpha},$$

а

$$z_\beta = z_{1-\beta}, \qquad \beta = 1 - Power.$$

Полученное n — размер одной variation при split 50/50.